전처리와 저장 — Kafka 메시지를 Parquet 과 PostgreSQL 에

메타코드 데이터 엔지니어 7기 · 이유석 · 이커머스 클릭 로그 추천 파이프라인 · 코드: preprocess.py, schema.sql

1. 처리 흐름 — Kafka 에 쌓인 메시지를 꺼내서, 다듬고, 두 군데에 저장한다

Kafka (user-events) → Spark → ① Parquet 파일 (원본 보관용) + ② PostgreSQL (조회용)

- 꺼내기: producer 가 Kafka 에 넣어 둔 45일치 메시지 919,497건을 Spark 가 읽는다. 어디까지 읽었는지 적어 두기 때문에(체크포인트) 다시 실행하면 새로 들어온 것만 읽는다
- 다듬기: JSON 을 풀어서 글자는 시각으로, 숫자는 숫자로 바꾼다. 필수 값이 빠졌거나 종류가 이상한 메시지는 버리지 않고 DLQ 토픽에 따로 모은다. 같은 이벤트가 두 번 있으면 하나만 남긴다
- 저장: Parquet 에는 날짜별로 전부 쌓고(안 지움), PostgreSQL 에는 이벤트 표(events)에 넣은 뒤 "1분 동안 상품별로 몇 번 봤나" 표(item_stats_1m)를 다시 세고, 가장 최근 이벤트 기준 30일 지난 행은 지운다

실행 결과: 읽음 919,497 · 정상 919,497 · DLQ 0 · 중복 116 제거 · DB 신규 919,381 · 집계 887,413행 · 30일 밖 301,050행 삭제 · 62.5초

2. 입력 · 출력 예시 — 들어올 때와 저장된 뒤 모습

들어올 때 (Kafka 메시지 1건)	저장된 뒤 (events 표의 1행)
{"event_id":"56b41caa-...", "event_type":"addtocart", "event_time":"2015-05-03T03:00:04.384Z", "payload":{"visitor_id":693516, "item_id":297662, "transaction_id":null}} → 전부 글자(JSON 문자열)	event_id 56b41caa-... (고유 번호) event_type addtocart · event_time 2015-05-03 03:00:04 (진짜 시각 타입) visitor_id 693516 · item_id 297662 (진짜 숫자 타입) · transaction_id 비어 있음

뭘 했나	어떻게	왜
자료형	"2015-05-03T03:00:04Z" 같은 글자를 시각으로, "693516" 을 숫자로 바꿈	글자인 채로는 "몇 분 동안", "몇 번" 같은 계산을 못 한다
시각	집계는 실제로 클릭한 시각(event_time) 기준. 보낸 시각·저장된 시각은 따로 적어 둠	늦게 도착해도 원래 그 시각의 집계에 들어가야 맞다. 세 시각의 차이가 곧 지연 시간
빠진 값·이상한 값	필수 값이 없거나 종류가 view/addtocart/transaction 이 아니면 DLQ 에 이유를 붙여 보냄	그냥 버리면 데이터가 사라지고, 멈추면 전체가 선다. 따로 모아 두고 나중에 고친다
중복	event_id 가 같으면 하나만. DB 는 같은 번호가 또 오면 무시. 집계는 더하지 않고 처음부터 다시 셈	같은 CSV 를 다시 돌려도 event_id 가 똑같이 나오게 만들어 놔서(내용 해시) 재실행해도 안 늘어난다. 원본에 똑같은 행 116건이 있었는데 이것도 걸러짐

3. 최종 스키마

events	자료형	뜻
event_id (고유 키)	uuid	(시각|유저|종류|상품) 해시. 같은 내용이면 같은 값 → 중복 판단
event_type	text	view / addtocart / transaction
event_time	timestamptz	클릭한 시각 (UTC). 집계 기준
visitor_id	bigint	유저
item_id	bigint	상품
transaction_id	bigint, null	구매일 때만 주문 번호
produced_at / ingested_at	timestamptz	보낸 시각 / DB 에 들어온 시각
schema_version / source	int / text	메시지 형식 버전 / 출처

item_stats_1m	자료형	뜻
window_start (고유 키 1)	timestamptz	어느 1분
item_id (고유 키 2)	bigint	어떤 상품
view_cnt	int	조회 몇 번
addtocart_cnt	int	장바구니 몇 번
transaction_cnt	int	구매 몇 번
unique_visitors	int	유저 몇 명
updated_at	timestamptz	마지막 계산 시각

4. 저장 포맷과 선택 이유 — PostgreSQL 은 최근 30일만(조회용), Parquet 은 전부(보관용)

어디에	실제로 저장된 것	왜 여기에
PostgreSQL (최근 30일)	events 618,331줄 · 2015-05-18 ~ 06-17 (view 598,704 · 장바구니 14,807 · 구매 4,820) · item_stats_1m 596,685줄. 그 전 301,050줄은 삭제됨	"이 유저가 뭘 봤나", "이 상품이 몇 번 팔렸나" 처럼 조건 걸어서 바로 찾아봐야 한다. 최근 것만 두니까 가볍고 빠르다. 같은 걸 다시 넣어도 결과가 안 변한다
Parquet (전부)	data/parquet/events/dt=2015-05-03 ~ 06-17 (46일 폴더) · 919,381줄 · 54MB	Kafka 는 7일, PostgreSQL 은 30일 지나면 지워진다. 전체 이력은 여기만 있다. 집계 코드를 고치거나 옛날 구간을 봐야 하면 그 날짜 폴더만 읽어서 다시 돌린다
DLQ (Kafka 토픽)	깨진 메시지 2건 (JSON 아님 · 종류 이상)	원문 그대로 두고 왜 실패했는지 적어 둔다. 고치면 다시 보낼 수 있다

다시 돌려 봤더니: (23,000건으로 확인) 그냥 재실행 → 새로 읽을 게 없어서 아무 것도 안 함 · 처음부터 재처리 → DB 신규 0 / 이미 있음 23,000, 집계 결과 똑같음 · 단, Parquet 은 파일이 한 번 더 쌓임 (읽을 때 event_id 로 걸러야 함, 남은 문제)